

Relación entre la autonomía y la capacidad de la batería en vehículos eléctricos: un análisis no paramétrico

Lubin Fernando Abaunza Melo¹

Asignatura: Teoría de estadística no paramétrica
Universidad Nacional de Colombia

12 de Julio , 2025

Resumen

Este trabajo aplica métodos de estadística no paramétrica para analizar la relación entre la autonomía y la capacidad de batería en 478 modelos de vehículos eléctricos. A través de un análisis descriptivo y modelos de regresión no paramétrica (Kernel, KNN y LOESS), se muestra cómo la autonomía aumenta con la capacidad de la batería, aunque con distintas tasas de crecimiento. El modelo KNN resultó ser el más preciso en la predicción. Los resultados destacan la utilidad de los métodos no paramétricos para explorar datos reales sin imponer supuestos estrictos de forma funcional.

1. Introducción

En medio de la transición energética global, los vehículos eléctricos se han consolidado como una alternativa sostenible para reducir emisiones y transformar el sector del transporte. Su crecimiento ha sido impulsado por avances tecnológicos, políticas de incentivo y una creciente conciencia ambiental, lo que convierte su estudio en una temática relevante para el análisis estadístico aplicado.

Este trabajo, titulado *Relación entre la autonomía y la capacidad de la batería en vehículos eléctricos: un análisis no paramétrico*, tiene como objetivo aplicar herramientas de estadística no paramétrica —particularmente técnicas de regresión— para explorar la relación entre dos variables clave: la autonomía estimada en kilómetros (`range_km`) y la capacidad de la batería en kilovatios-hora (`battery_capacity_kWh`).

Para ello se utiliza el conjunto de datos *Electric Vehicle Specs Dataset (2025)*, disponible en la plataforma Kaggle, que reúne información técnica de 478 modelos de vehículos eléctricos. Además de las variables mencionadas, incluye detalles como eficiencia energética y tipo de carrocería, lo cual ofrece un contexto rico para el análisis.

El estudio se estructura en tres partes: primero se realiza un análisis descriptivo exploratorio de la autonomía; luego se describen las características de la capacidad de la batería; y finalmente se aplican y comparan distintos modelos de regresión no paramétrica. Estos modelos permiten capturar patrones complejos y no lineales en los datos, superando las limitaciones de los enfoques lineales tradicionales.

Más allá de abordar una problemática aplicada, el propósito del trabajo es reforzar los conceptos vistos durante el curso de Estadística No Paramétrica y evidenciar su utilidad en el análisis de datos reales y actuales, especialmente en un campo en constante evolución como el de la movilidad eléctrica.

2. Marco Teórico

Este trabajo se enmarca dentro de la estadística no paramétrica, aplicada al análisis de datos técnicos de vehículos eléctricos. En particular, se estudia la relación entre dos variables cuantitativas continuas: la autonomía en kilómetros (`range_km`) y la capacidad de la batería en kilovatios-hora (`battery_capacity_kWh`). Este enfoque permite analizar los datos sin asumir una forma funcional específica para la distribución o la relación entre variables, adaptándose mejor a estructuras complejas.

Las técnicas aplicadas incluyen análisis univariado de las variables y métodos de regresión no paramétrica.

2.1. Análisis de Densidad y Curvas de Confianza

Se aplicó una **estimación de densidad kernel** para estudiar la distribución de las variables `range_km` y `battery_capacity_kWh`. Esta técnica suaviza los datos para generar una curva continua que aproxima la función de densidad de probabilidad de la muestra. El estimador se define como:

$$\hat{f}_h(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - x_i}{h}\right) \quad (1)$$

donde $K(\cdot)$ es el núcleo Gaussiano y h el **ancho de banda**, que se seleccionó mediante la **regla de referencia a la normal**:

$$h_0 = 1,059 \cdot \min\left\{\text{sd}, \frac{\text{IQR}}{1,35}\right\} \cdot n^{-1/5} \quad (2)$$

Además, se calcularon **intervalos de confianza punto a punto** del 95 % para la función de densidad estimada. Para ello se empleó el **método delta**, que permite aproximar un intervalo de confianza para el valor esperado del estimador kernel $\mathbb{E}[\hat{f}_h(x)]$, utilizando la varianza asintótica del estimador en cada punto.

2.2. Curvas Esperadas y de Varianza (Bootstrap)

Con el método *bootstrap* (re-muestreo con reemplazo), se generaron múltiples estimaciones de densidad para ambas variables. A partir de ellas, se construyó una **curva esperada** $\mathbb{E}[\hat{f}_h(x)]$ y una **curva de varianza** $\text{Var}[\hat{f}_h(x)]$, que permiten analizar la estabilidad y la variabilidad de la estimación en distintos valores de la variable.

2.3. Regresión No Paramétrica

Se modeló la relación entre `battery_capacity_kWh` (regresora) y `range_km` (respuesta) mediante tres enfoques no paramétricos:

- **Regresión Kernel:** ajusta la curva suavizada usando una ventana de ponderación centrada en cada punto, sin suponer una relación funcional específica. La estimación del valor esperado de Y dado $X = x$ se calcula como:

$$\hat{m}(x) = \frac{\sum_{i=1}^n K_h(x - x_i) y_i}{\sum_{i=1}^n K_h(x - x_i)} \quad (3)$$

donde $K_h(u) = \frac{1}{h} K\left(\frac{u}{h}\right)$ es un núcleo suavizante con ancho de banda h , y (x_i, y_i) son las observaciones muestrales. Se evaluó su precisión mediante MSE y MAE sobre un conjunto de prueba.

- **Regresión KNN (k-vecinos más cercanos):** estima la respuesta como el promedio de las respuestas correspondientes a los k valores más cercanos de x . Se optimizó el valor de k minimizando el MSE.
- **Regresión LOESS (Locally Weighted Regression):** utiliza estimación local polinomial con un parámetro de suavizamiento optimizado mediante el método `dpill`. La predicción en los puntos de prueba se realizó por interpolación.

Finalmente, se compararon los tres modelos en términos de su desempeño predictivo, evaluando los errores medios cuadrático (MSE) y absoluto (MAE). Este enfoque permite capturar relaciones complejas y no lineales que podrían no ser detectadas por modelos tradicionales, lo que resulta especialmente útil en contextos tecnológicos como el de los vehículos eléctricos.

3. Análisis de Datos

Se analizaron 478 modelos de vehículos eléctricos con el fin de estudiar la relación entre la autonomía (`range_km`) y la capacidad de la batería (`battery_capacity_kWh`). El análisis se organiza en tres partes: primero se describe la variable *autonomía*; luego se estudia la *capacidad de batería*; y finalmente se aplican modelos no paramétricos para explorar y modelar la relación entre ambas variables.

3.1. Autonomía (`range_km`)

La Tabla 1 presenta los principales estadísticos descriptivos de la variable *autonomía*. Se observa que los vehículos eléctricos tienen una mediana de 397.5 km y un rango intercuartílico (RIC) de 150 km, lo cual evidencia una dispersión considerable entre los modelos analizados. Además, la menor autonomía registrada es de 135 km, mientras que la mayor alcanza los 685 km.

Estadístico	Mínimo	Mediana	Máximo	RIC
Autonomía (km)	135	397.5	685	150

Cuadro 1: Estadísticos descriptivos de la variable *autonomía* (`range_km`).

La Figura 1 muestra la estimación de la densidad kernel para la variable *autonomía*, utilizando un núcleo Gaussiano y un ancho de banda óptimo. La distribución presenta múltiples modos, lo cual sugiere la posible existencia de subgrupos diferenciados dentro del conjunto de vehículos, probablemente relacionados con diferencias tecnológicas o de diseño.




Figura 1: Estimación de la función de densidad kernel para la autonomía (*range_km*). Las líneas punteadas corresponden a un intervalo de confianza del 95 %, calculado mediante el método delta.

La Figura 2 muestra las curvas bootstrap de la esperanza $\mathbb{E}[\hat{f}_h(x)]$ y varianza $\text{Var}[\hat{f}_h(x)]$ del estimador kernel. La curva esperada confirma la multimodalidad observada previamente, mientras que la curva de varianza se mantiene baja en la mayor parte del dominio, lo que sugiere una estimación estable. Se observan ligeros aumentos en la varianza en las zonas donde la densidad presenta más cambios, lo cual es esperable ya que en esas regiones la estimación se vuelve menos precisa.




Figura 2: Curvas bootstrap para la estimación de densidad kernel de la autonomía: (izquierda) esperanza $\mathbb{E}[\hat{f}_h(x)]$, (derecha) varianza $\text{Var}[\hat{f}_h(x)]$.

3.2. Capacidad de batería (*battery_capacity_kWh*)

La Tabla 2 presenta los principales estadísticos de la variable *capacidad de batería*. Se observa que la mediana es de 761.5 kWh y el rango intercuartílico (RIC) alcanza los 306 kWh, lo que indica una considerable dispersión en los datos. Además, se identificó un valor mínimo de 213 kWh y un máximo de 1180 kWh.

Estadístico	Mínimo	Mediana	Máximo	RIC
Capacidad (kWh)	213	761.5	1180	306

Cuadro 2: Estadísticos descriptivos de la variable *capacidad de batería* (*battery_capacity_kWh*).

La Figura 3 muestra la estimación de densidad kernel para esta variable, acompañada de un intervalo de confianza al 95 % obtenido mediante el método delta. La forma de la curva revela la presencia de múltiples modos, lo cual indica una distribución heterogénea entre los diferentes modelos de vehículos.




Figura 3: Estimación de la función de densidad kernel de la capacidad de batería (*battery_capacity_kWh*). Las líneas punteadas representan un intervalo de confianza al 95 %, calculado mediante el método delta.

En la Figura 4 se presentan las curvas obtenidas mediante el enfoque bootstrap para la media $\mathbb{E}[\hat{f}_h(x)]$ y la varianza $\text{Var}[\hat{f}_h(x)]$ del estimador kernel. Se observa que la estimación es estable en la mayoría del dominio, aunque en zonas con mayor variabilidad estructural la varianza se incrementa ligeramente.




Figura 4: Estimación bootstrap para la densidad de la capacidad de batería: (izquierda) curva esperada $\mathbb{E}[\hat{f}_h(x)]$, (derecha) curva de varianza $\text{Var}[\hat{f}_h(x)]$.

3.3. Modelos de Regresión No Paramétrica

En la siguiente sección se comparan tres enfoques de regresión no paramétrica: Kernel, KNN y LOESS, aplicados para modelar la relación entre la autonomía y la capacidad de batería. Los resultados se evalúan mediante métricas de error de predicción y visualizaciones de ajuste.

3.3.1. Regresión Kernel

La Figura 5 muestra el ajuste del modelo de regresión kernel, donde se observa una relación positiva y suavizada entre la capacidad de batería y la autonomía. Las bandas de confianza del 95 % reflejan la variabilidad de la estimación y sugieren un posible aplanamiento en niveles altos de capacidad.




Figura 5: Regresión kernel con bandas de confianza al 95 % para la relación entre autonomía y capacidad de batería.

Para evaluar la validez del modelo, se realizaron dos pruebas gráficas complementarias: el *test de no efecto* y el *test de linealidad*. Como se muestra en la Figura 6, el *test de no efecto* rechaza visualmente la hipótesis de independencia entre las variables (la banda azul se aleja notoriamente del cero), mientras que el *test de linealidad* sugiere que, aunque la relación general es aproximadamente lineal, existen pequeñas desviaciones no capturadas por un modelo estrictamente lineal, especialmente en los extremos del rango de datos.




Figura 6: Evaluación visual de la regresión kernel: (izquierda) test de no efecto; (derecha) test de linealidad.

El desempeño del modelo de regresión kernel en el conjunto de prueba se resume en la Tabla 3, donde se reportan el error cuadrático medio (MSE) y el error absoluto medio (MAE).

Métrica	Valor
MSE	1960.08
MAE	34.62

Cuadro 3: Métricas de error del modelo de regresión kernel sobre el conjunto de prueba.

3.3.2. Regresión KNN

La Figura 7 muestra la curva ajustada por el modelo de regresión KNN utilizando $k = 5$, valor seleccionado mediante validación en el conjunto de prueba. El modelo logra capturar la tendencia creciente entre la capacidad de batería y la autonomía de los vehículos eléctricos.

Visualmente, la curva sigue de manera más cercana los datos observados, lo que sugiere un mayor ajuste.




Figura 7: Curva de regresión KNN con $k = 5$, ajustada sobre los datos de entrenamiento.

El desempeño del modelo de regresión kNN en el conjunto de prueba se resume en la Tabla 4, donde se reportan el error cuadrático medio (MSE) y el error absoluto medio (MAE).

Métrica	Valor
MSE	1349.97
MAE	29.3

Cuadro 4: Métricas de desempeño en el conjunto de prueba para los modelos no paramétricos.

3.3.3. Regresión LOESS

La Figura 8 muestra la curva ajustada con regresión LOESS ($h = 16.57$). Se observa una relación creciente entre la capacidad de batería y la autonomía, aunque con más fluctuaciones locales que podrían deberse a sobreajuste en algunas zonas.




Figura 8: Curva de regresión LOESS para predecir la autonomía en función de la capacidad de la batería.

El desempeño del modelo de regresión LOESS en el conjunto de prueba se resume en la Tabla 5, donde se reportan el error cuadrático medio (MSE) y el error absoluto medio (MAE).

Métrica	Valor
MSE	1641.6
MAE	31.52

Cuadro 5: Métricas de error del modelo de regresión LOESS sobre el conjunto de prueba.

3.3.4. Comparación de Modelos

La Tabla 6 resume el desempeño predictivo de los tres modelos evaluados: regresión Kernel, KNN y LOESS. Se reportan las métricas de error cuadrático medio (MSE) y error absoluto medio (MAE) calculadas sobre el conjunto de prueba. El modelo KNN presenta el mejor desempeño, con los valores más bajos en ambas métricas, lo que sugiere un ajuste más cercano a los datos observados.

Modelo	MSE	MAE
Regresión Kernel	1960.08	34.62
Regresión KNN	1349.97	29.30
Regresión LOESS	1641.60	31.52

Cuadro 6: Comparación del desempeño de los modelos de regresión no paramétrica sobre el conjunto de prueba.

4. Discusión

El análisis realizado mostró una relación clara y positiva entre la capacidad de la batería y la autonomía de los vehículos eléctricos: en general, a mayor capacidad, mayor es la distancia que puede recorrer el vehículo con una sola carga.

Entre los tres modelos de regresión no paramétrica aplicados (Kernel, KNN y LOESS), el modelo KNN fue el que tuvo mejor desempeño, ya que presentó los menores errores de predicción (tanto MSE como MAE). Esto sugiere que el modelo logró ajustarse muy bien a los datos, capturando sus patrones sin imponer una forma fija. Sin embargo, este tipo de modelo puede presentar irregularidades en la curva estimada y ser menos estable en zonas con pocos datos.

La regresión Kernel también mostró una tendencia creciente clara, y aunque sus errores fueron un poco mayores que los del modelo KNN, ofreció un ajuste más suave y continuo. Además, incluyó bandas de confianza que permiten ver qué tan confiable es la estimación en cada punto del rango de datos.

Por su parte, la regresión LOESS también capturó correctamente la relación entre las variables, aunque la curva estimada presentó más variaciones locales. Esto puede ser resultado de un ajuste muy detallado (sobreajuste) en algunas partes del dominio. Aun así, sus resultados fueron buenos y se ubicaron entre los de los otros dos modelos.

El análisis descriptivo de las variables autonomía y capacidad de batería mostró que ambas tienen distribuciones dispersas y con múltiples picos (modos), lo que podría reflejar la existencia de diferentes tipos de vehículos eléctricos en el mercado, como autos urbanos, SUV o de alta gama.

En general, los métodos no paramétricos permitieron modelar los datos de forma flexible, sin imponer supuestos sobre la forma de la relación. Esto los hace especialmente útiles para analizar datos tecnológicos, como los de vehículos eléctricos, que cambian y evolucionan constantemente.

Referencias

- [1] Urvish Ahir. *Electric Vehicle Specifications Dataset (2025)*. Kaggle. Disponible en: <https://www.kaggle.com/datasets/urvishahir/electric-vehicle-specifications-dataset-2025/data>
- [2] Giraldo, R. (2025). *Estadística No Paramétrica: Alternativas a Pruebas Clásicas, Estimación de la Densidad y Análisis de Regresión. Ilustraciones con R*. Departamento de Estadística, Universidad Nacional de Colombia, Sede Bogotá. Disponible en: <https://sites.google.com/a/unal.edu.co/ramon-giraldo-webpage/>

Anexos

A. Código fuente en R

El código completo utilizado para el análisis de datos —incluyendo la carga de datos, el análisis descriptivo, la estimación de densidades kernel y los modelos de regresión no paramétrica (Kernel, KNN y LOESS)— se encuentra disponible en el archivo adjunto:

- `modelo_autonomia_bateria.R`

Este script puede ejecutarse directamente en R o RStudio, y permite reproducir todos los resultados y figuras presentados en este informe.

B. Fuente de los datos

Los datos utilizados en este trabajo fueron tomados del siguiente recurso abierto:

- Kaggle — *Electric Vehicle Specs Dataset (2025)*
<https://www.kaggle.com/datasets/urvishahir/electric-vehicle-specifications-dataset-2025/data>